

中原大學
資料探勘導論
期末專題書面報告

非監督式學習於 PPG 抗噪之應用與比較：
以 K-Means 與 DBSCAN 為例

指導教授：吳宜鴻 博士

學生：位衡

中華民國 一 一 五 年 一 月

摘要

光體積變化描記圖 (Photoplethysmography, PPG) 因其非侵入性與低成本優勢，已廣泛應用於穿戴式健康監測裝置。然而，PPG 訊號極易受受測者動作影響而產生動作偽影 (Motion Artifacts, MA)，嚴重降低心率估測之準確度。針對缺乏標籤數據的實際應用場景，本研究旨在探討非監督式學習演算法自動識別並剔除偽影之可行性。

本研究使用包含 9 種日常活動 (如靜止、飲食、行走、上下樓梯等) 之 PPG 數據集「PPG-DaLiA」，並參考 Roy, Gupta and Sharma (2020) 提取訊號之統計特徵與非線性特徵 (如樣本熵 Sample Entropy、碎形維度 Higuchi Fractal Dimension)，並分別採用基於劃分的 K-Means 與基於密度的 DBSCAN 演算法進行分群效能比較。

實驗結果顯示，K-Means (K=3) 能成功依據訊號品質將數據劃分為「靜止狀態」、「輕微動作干擾」與「嚴重動作偽影」三類。經心電圖 (ECG) 驗證，被識別為「嚴重動作偽影」的群聚在心率估測有著明顯誤差，證明該方法能有效過濾高變異雜訊。相較之下，DBSCAN 由於生理訊號特徵在空間中呈現連續分佈特性，缺乏明顯密度斷層，導致其傾向將大部分數據歸類為單一群聚，或在嚴格參數下造成有效數據的過度剔除。

本研究結論指出，針對具連續變化特性之 PPG 訊號抗噪任務，基於劃分的 K-Means 演算法在穩定性與實用性上均優於基於密度的 DBSCAN 演算法。

目錄

摘要.....	1
研究動機.....	4
研究方法.....	5
1.1 資料集介紹與前處理.....	5
1.2 特徵工程.....	6
1.3 非監督式分群演算法.....	7
研究結果.....	9
2.1 特徵空間分佈與物理意義.....	9
2.2 K-Means 分群效能分析.....	9
2.2.1 群聚意義分析.....	9
2.2.2 頻域特性驗證.....	10
2.2.3 心率誤差定量驗證.....	11
2.3 DBSCAN 分群效能分析.....	13
2.3.1 參數測試結果.....	13
2.3.2 群聚意義分析.....	15
2.3.3 頻域特性驗證.....	16
2.3.4 心率誤差定量驗證.....	16
討論.....	18
3.1 生理訊號的特性.....	18
3.1.1 DBSCAN 的劣勢.....	18
3.1.2 K-Means 的優勢.....	19
3.2 節律性運動的陷阱.....	19
3.2.1 DBSCAN 的劣勢.....	19
3.2.2 K-Means 的優勢.....	20

結論.....	20
參考文獻.....	21

研究動機

隨著穿戴式科技的快速發展，光體積變化描記圖 (Photoplethysmography, PPG) 因具備非侵入性、低成本與硬體架構簡單等優勢，已成為智慧手錶與健康手環中監測心率的核心理論。PPG 的基本原理，如圖 1，是利用光學感測器偵測微血管內血液容積隨心跳產生的週期性變化，藉由血液對光的吸收差異來推算心率。




圖 1 PPG 原理示意圖 <https://www.ansys.com/blog/modeling-human-skin-and-optical-heart-rate-sensors>

然而，這種依靠光路徑偵測的機制，在真實生活的連續監測應用中面臨巨大挑戰。當受測者進行行走、跑步等活動時，感測器與皮膚之間的相對位移、以及肌肉收縮都會導致光強度發生劇烈波動。這些被稱為動作偽影 (Motion Artifacts, MA) 的干擾訊號，其能量往往遠大於微弱的心跳訊號，會嚴重扭曲光學波形，導致心率估測產生巨大誤差，甚至使數據完全失去參考價值。

目前學術界雖有多種抗噪演算法被提出，但大多依賴監督式學習，需要大量的人工標註數據來訓練模型。然而，在實際的使用者場景中，我們無法預先取得每個瞬間的真實活動標籤或心率真值。這導致傳統依賴標籤的方法在面對未知且多變的日常活動時，難以進行即時且有效的品質評估。

因此，如何在缺乏標籤數據的情況下，開發一套能自動識別並剔除動作偽影的非監督式學習機制，成為提升穿戴式裝置可靠度的關鍵挑戰。本研究旨在探討並比較兩種主流的非監督式分群演算法——基於劃分的 K-Means 與基於密度的 DBSCAN，評估其在無監督情境下自動區分 PPG 訊號品質之能力，期能為穿戴式裝置提供一套高效且準確的訊號品質指標。

研究方法

1.1 資料集介紹與前處理

本研究採用公開資料集 **"PPG Field Study Dataset"** 進行演算法驗證。該資料集由 Reiss 等人建立，旨在提供真實生活情境下含有豐富動作偽影 (Motion Artifacts) 的 PPG 訊號，以利抗噪演算法之開發與評估。

資料集共包含 15 位受測者 (7 男 8 女)，平均年齡 30.6 歲，本研究以 S7 受試者為例。實驗過程中，受測者同時配戴以下兩種裝置進行同步數據採集：

- **腕戴式裝置 (Wrist-worn device)**：使用 Empatica E4 智慧手環配戴於非慣用手，採集光體積變化描記圖 (PPG) 訊號，採樣率為 64 Hz。本研究主要使用此 PPG 訊號作為非監督式學習模型的輸入來源。
- **胸帶式裝置 (Chest-worn device)**：使用 RespiBAN Professional 裝置，以 700 Hz 的高採樣率記錄心電圖 (ECG) 訊號。

為了模擬真實生活中的連續動作干擾，受測者依序進行了 9 種不同強度的日常活動，涵蓋了從靜止到劇烈運動的多種情境。

- **靜態活動**：靜止閱讀 (Sitting)、駕駛 (Driving)、辦公 (Working)。
- **動態活動**：步行 (Walking)、上下樓梯 (Stairs)、桌上足球 (Table Soccer)、騎行 (Cycling)、午餐活動 (Lunch)。
- **過渡期間 (Transient)**：各活動之間的移動過程（如從停車場走到辦公室），此類別通常包含不穩定的動作雜訊。

本研究使用已經過同步處理的 .pkl 檔案格式提取 PPG 類比訊號、活動標籤 (Activity Labels) 與 ECG 心率真值 (Ground Truth HR)。

- **訊號同步**：原始數據已透過實驗前後的兩次「雙擊胸部 (Double tap)」動作，利用加速度訊號特徵完成了 Empatica E4 與 RespiBAN 之間的時間同步與漂移校正。

- **標籤對齊：** 由於原始活動標籤與心率真值的時間解析度不同，本研究在特徵提取階段採用 8 秒視窗對應之眾數 (Mode) 來決定該片段的活動類別，以確保分群結果能與真實活動精確對應。

1.2 特徵工程

由於 PPG 訊號在動作偽影 (Motion Artifacts) 干擾下會出現顯著的形態學變異，傳統的時域特徵（如波峰高度、脈衝寬度）往往難以準確提取。因此，本研究參考 Roy, Gupta and Sharma (2020) 出的非線性訊號分析架構，提取熵 (Entropy) 與碎形維度 (Fractal Dimension) 兩大類特徵，以量化時間序列的不規則程度與複雜度。

A. 熵特徵 (Entropy Features) - 量化訊號規律性

熵 (Entropy) 用於描述系統狀態的機率分佈與資訊量。在 PPG 分析中，高品質訊號通常具有高度的週期性（低熵值），而動作雜訊則會增加訊號的隨機性（高熵值）。

(1) 樣本熵 (Sample Entropy, SampEn)：

計算時間序列的隨機性，靜止狀態下的 PPG 波形規律且重複，SampEn 數值較低；當受測者進行不規則運動（如過渡動作）時，波形規律被破壞，導致 SampEn 顯著上升。本研究將其作為區分雜訊嚴重程度的關鍵指標。

$$SampEn = -\ln \frac{C_j^{m+1}(r)}{C_j^m(r)}$$

(2) 頻譜熵 (Spectral Entropy, SpecEn)：

在頻域中量化訊號的隨機性，乾淨的 PPG 訊號在頻域上具有明顯的單一主頻（即心跳頻率），能量集中，故熵值較低；而動作偽影通常表現為寬頻雜訊，能量分散於各頻段，導致 SpecEn 較高。

$$SpecEn = \sum_{i=1}^{N/2} P(i, l) \cdot \log \frac{1}{P(i, l)}$$

(3) 排列熵 (Permutation Entropy, PermEn) :

描述訊號的時間結構，直接反映時間序列中的動態變化，對於偵測訊號中突發的劇烈波動特別敏感。

B. 碎形維度特徵 (Fractal Dimension Features) - 量化波形粗糙度

(1) Higuchi 碎形維度 (Higuchi Fractal Dimension, HFD) :

在時域中直接計算曲線幾何複雜度，HFD 對於訊號的瞬態行為 (Transient behavior) 非常敏感。實驗發現，受動作干擾的 PPG 片段具有較高的 HFD 值，這與 SampEn 呈現高度正相關

(2) Petrosian 碎形維度 (Petrosian FD) :

基於訊號序列正負斜率變化率的快速演算法，提供另一種視角的波形複雜度評估，運算速度快，適合即時處理。

由於不同特徵的數值尺度差異巨大 (例如 SampEn 範圍約 0.1~0.6，而 HFD 範圍約 1.0~1.5)，為了避免特定特徵主導分群演算法的距離計算，本研究在送入 K-Means 與 DBSCAN 模型前，採用 Z-score 標準化處理。

1.3 非監督式分群演算法

經過特徵提取與標準化後，本研究將包含時域、頻域與非線性特徵的五維特徵向量輸入至兩種邏輯截然不同的非監督式學習演算法，以探討不同分群策略在 PPG 抗噪任務上的適用性。

A. K-Means

K-Means 是一種基於劃分 (Partition-based) 的分群方法，會將數據分為 K 個不同的群集，每個群集由其內部的數據點的相似性來定義。演算

法核心步驟是重複：1. 隨機選出 K 個中心點；2. 將資料點分派給最近的中心；3. 更新中心點為該群的平均值；直到中心點不再大幅變動即完成。

本研究參數設定為 $K = 3$ ，我們假設 PPG 訊號品質並非二元對立，而是存在中間過渡狀態。因此，強制劃分為三群旨在對應以下物理意義：

1. **乾淨訊號**：對應靜止狀態，特徵數值（如熵與碎形維度）最小。
2. **輕微干擾**：對應日常輕微活動，特徵數值中等。
3. **嚴重偽影**：對應劇烈運動，特徵數值最大。

K-Means 的程式邏輯會隨機初始化 3 個群聚中心，並計算每個樣本點（五維向量）與中心點的歐幾里得距離，將樣本分配至最近的中心；接著重新計算各群的平均值並更新中心點，反覆迭代直至收斂。最後輸出分群標籤。

B. DBSCAN

DBSCAN 是一種基於密度的聚類演算法，根據數據點周圍的密度來擴展聚類。與 K-Means 不同，它不需要預先指定群數，而是透過數據點的「密度連接性」來定義群聚，並能自動識別離群雜訊 (Noise)。

本研究在參數設定上 `min_samples` 設為 20，接著利用 K-distance 計算最佳半徑，為了驗證不同半徑值對分群效能的影響，本研究進一步執行了參數敏感度測試。我們假設「正常的生理訊號」會在特徵空間中形成高密度的核心群聚，而「動作偽影」則應為密度較低的離散雜訊。

DBSCAN 的程式邏輯會先對於任意樣本點，若其的半徑 (`eps`) 內的鄰居數量大於 `min_samples` 則將視為核心點並形成群聚；接著透過核心點不斷吸收密度可達的鄰居擴展範圍；如果有一樣本點既非核心點也不在任一核心點的半徑範圍內，則將其視為雜訊 (-1)。最後輸出群聚標籤，而 -1 就是被演算法視為雜訊剔除掉的片段。

研究結果

本章節展示非監督式學習模型在 PPG 訊號品質評估上的具體表現。實驗結果分為三個部分：首先分析特徵空間的分佈特性，其次驗證 K-Means 分群對心率準確度的提升成效，最後與 DBSCAN 進行比較分析。

2.1 特徵空間分佈與物理意義

為了驗證特徵工程的有效性，我們將提取的 樣本熵 (SampEn) 與 Higuchi 碎形維度 (HFD) 繪製於二維平面。




圖 2 PPG 訊號在特徵空間之分佈圖。

左： K-Means (K=3)，右： DBSCAN (eps=0.75, min_samples=20)。

從圖 2 可觀察到數據點呈現連續分佈，從左下角的「低熵/低複雜度」區域（對應靜止狀態），平滑過渡到右上角的「高熵/高複雜度」區域（對應隨機動作），中間並無明顯的斷層或獨立區塊。K-Means 強制將連續空間「切分」為三個區塊，分別為 Cluster 2 (黃色，乾淨區)、Cluster 1 (藍綠色，過渡區) 與 Cluster 0 (紫色，複雜區)；而 DBSCAN 在這個二維特徵的分佈圖中呈現明顯的群聚分離，。

2.2 K-Means 分群效能分析

2.2.1 群聚意義分析

首先我們檢查了 K-Means 每一群聚中包含的真實活動標籤，如圖 3，發現不同分群有顯著的活動分佈差異：




圖 3 K-Means 各群聚之真實活動組成比例

- Cluster 2 包含 94% 的 Sitting：這暗示此群聚可能代表「乾淨訊號」。
- Cluster 0 包含 52% 的 Lunch 與 55% 的 Cycling：這些屬於非規律或輕微動作。
- Cluster 1 包含 95% 的 Stairs 與 93% 的 Walking：行走與上下樓梯屬於具節律性的劇烈動作。這類動作通常會產生與心跳頻率相近的動作偽影，最容易干擾心率計算。因此，我們高度懷疑 Cluster 1 為主要雜訊來源。

2.2.2 頻域特性驗證

為了證實上述懷疑，我們從 Cluster 2 與 Cluster 1 中隨機抽取樣本，進行功率譜密度 (PSD) 分析。




圖 4 K-Means Cluster 2 (上) 與 Cluster 1 (下) 之時頻域特性比較

從圖 4 可以看出 Cluster 2 (疑似乾淨群) 的頻譜圖 (右上) 顯示出單一且尖銳的主峰 (Dominant Peak)，這是典型的高品質心跳訊號特徵；而 Cluster 1 (疑似雜訊群) 的頻譜圖 (右下) 呈現混亂的寬頻分佈，缺乏單一主峰，且時域波形 (左下) 充滿毛刺。本研究認為頻域分析證實了 Cluster 1 在物理本質上屬於「低品質雜訊」。

2.2.3 心率誤差定量驗證

ECG 比對是評估分群對最終應用 (心率監測) 影響的黃金標準。我們計算各群聚 PPG 估測心率與 ECG 真值之絕對誤差 (Absolute Error)，量化其準確度差異。




圖 5 K-Means 各群聚之心率絕對誤差分佈箱型圖

透過圖 5 可以看出 Cluster 1 (雜訊群) 的箱型圖顯示其上四分位數誤差高達將近 40 BPM，且變異數極大；Cluster 0 雖然最大值誤差接近 20 BPM，但整體誤差還是控制在 10 BPM 以內；而 Cluster 2 (乾淨群) 誤差極低，全數樣本落在可接受的 10 BPM 範圍內。




圖 6 K-Means PPG 估測心率 vs ECG 真值散佈圖

透過圖 6 發現 Cluster 1 (雜訊群) 的散佈圖顯示估測值嚴重偏離 ECG 真值，呈現無相關性的隨機分佈；Cluster 0 呈現輕微發散，符合輕微動作干擾的物理定義；而 Cluster 2 (乾淨群) 的散佈圖顯示其與 ECG 真值高度吻合。

從以上兩個結果得知 Cluster 1 為導致心率估測失效的主要來源，Cluster 2 則保留了完整的生理資訊。綜合頻譜分析與 ECG 誤差驗證，本實驗證實：

1. Cluster 1 確實對應到物理上的「動作偽影」與應用上的「高誤差片段」。
2. K-Means (K=3) 在無標籤監督下，成功依據訊號的非線性特徵（熵與碎形維度），將不可用的雜訊自動分離。

2.3 DBSCAN 分群效能分析

2.3.1 參數測試結果

為了決定最佳的掃描半徑，本研究首先透過 K-distance 算出最佳半徑建議值大約為 0.75。然而，考慮到生理訊號特徵的連續性，單一數學指標可能無法反映最佳的物理分類邊界，因此本研究進一步執行了參數敏感度測試。




圖 7 DBSCAN 各參數標籤之真實活動組成比例

(左上：0.75，右上：0.5，左下：0.3，右下：0.2)

透過圖 7 的四種情境可觀察到極端的演算法行為，上方較大的半徑 (0.75、0.5)代表了較寬鬆的分群，絕太多的數據都被歸類在單一核心群聚 (Label 0)，被判定為雜訊 (Label -1) 的趨近為 0，這證實了 Walking 等節律性偽影在特徵空間中具有極高密度，且與正常訊號區域相連，過於寬鬆的半徑導致演算法將雜訊與訊號湊在一起，完全喪失濾波能力；而右下極小的半徑 (0.2) 代表了極嚴格的分群，演算法將所有活動標記為雜訊，我們認為是因為此時半徑小於生理訊號自然的變異範圍，導致任何群聚皆無法滿足密度條件；而左下介於中間的參數 (0.3)，是唯一具有鑑別度的操作點，因此後續章節將聚焦於 $\text{eps}=0.3$ 的結果。

也可以從圖 2 跟圖 7 的比較發現，半徑 0.75 的 DBSCAN 即使在二維特徵空間的分佈圖中呈現明顯的分群，但當五維特徵空間中不同的活動被視為了同一群聚，可能是某些特徵的相似性掩蓋了其他特徵的差異性。

2.3.2 群聚意義分析

我們深入探討 DBSCAN (eps=0.3) 判定為雜訊 (Label -1) 的數據中，究竟包含了哪些真實活動。




圖 8 DBSCAN 各標籤之真實活動組成比例

透過圖 8 我們可以發現 DBSCAN 的篩選邏輯存在嚴重缺陷，對於訊號品質應最穩定的 Sitting 與 Working，DBSCAN 竟分別將 34% 與 38% 的數據標記為雜訊，這顯示 DBSCAN 對於局部密度變化過於敏感，即使是正常的靜止訊號，只要密度稍低就會被錯誤剔除。對於 Walking，DBSCAN 將其分裂為 43% 的 Noise (-1) 與 57% 的 Label 1。這意味著它無法像 K-Means 那樣穩定鎖定同一類型的動作偽影。

2.3.3 頻域特性驗證

為了驗證上述被「誤殺」的靜態活動是否真的有問題，我們從 DBSCAN 的 Label -1 中隨機抽取樣本進行功率譜密度 (PSD) 分析。




圖 9 DBSCAN Label 0 (上) 與 Label -1 (下) 之時頻域特性比較

透過圖 9 可以看出被 DBSCAN 判定為雜訊的片段 (左下) 的時域波形清晰，且頻譜圖 (右下) 顯示出極為乾淨的單一主峰 (75 BPM)，無明顯雜訊干擾，由此頻域證據得知該訊號在物理上是完美的生理訊號，僅因特徵空間分佈問題就被演算法剔除。

2.3.4 心率誤差定量驗證

最後，我們利用各群聚 PPG 估測心率與 ECG 真值之絕對誤差來量化這些被剔除數據的實際品質，確認誤殺的嚴重程度。




圖 10 DBSCAN 各標籤之心率絕對誤差分佈箱型圖

透過圖 10 可以看到 Label -1 雖然定義為雜訊，但其誤差分佈相對收斂，可以看到四分位數極低，甚至接近 0 BPM，這代表雜訊群中混雜了大量低誤差的優質訊號，證實了演算法可能將好的訊號誤殺。DBSCAN 因為密度標準過嚴，將大量稍微不夠緊密的「好訊號」判定為雜訊剔除；而被視為 Label 1 的群聚之誤差上四分位數與最大值極高，顯示存在大量嚴重偏離真值的樣本，證實了走路等規律性動作形成了高密度的群聚，DBSCAN 誤判其為正常訊號予以保留。




圖 11 DBSCAN PPG 估測心率 vs ECG 真值散佈圖

透過圖 11 可以看到我們對比了核心群 (Label 0)、雜訊群 (Label -1) 與高密度群 (Label 1) 的估測表現，中間的 Label -1 被演算法視為雜訊，但可以看到還是有大量紅點落在對角線上，再次證實在雜訊群中混雜了乾淨的訊號；被演算法視為高密度群的 Label 1，橘點偏離對角線的情況更為嚴重，我們判斷這些是嚴重的動作偽影，而 DBSCAN 將其標記為獨立群聚。

綜合以下結果，本實驗證實 DBSCAN 的密度分群機制在 PPG 抗噪任務失效：

1. DBSCAN 被「走路」的高密度特徵欺騙，保留了最該剔除的訊號 (Label 1)。
2. DBSCAN 對「靜止」的密度變化過於敏感，剔除了該保留的訊號 (Label -1)。

相比之下，前述 K-Means 策略能有效避免此類邏輯倒置。

討論

本章節旨在深入探討實驗結果背後的物理機制，解釋為何不同分群策略在 PPG 抗噪任務中表現出截然不同的效能，並探討其在穿戴式裝置上的工程應用價值。

3.1 生理訊號的特性

由於 PPG 訊號特徵在空間中的分佈為連續性的，而非傳統分群任務中常見的離散性。這一特性直接決定了不同演算法的適用性。

3.1.1 DBSCAN 的劣勢

DBSCAN 的運作原理高度依賴於數據分佈中的密度斷層，理想情況下，不同類別（如乾淨訊號與雜訊）之間應該存在一片密度極低的區域，讓演算法能藉此將兩者斷開。但是從圖 2 可以看到 PPG 訊號的品質變化是連續的，當受試者從靜止狀態轉換到輕微動作再到劇烈運動的過程是呈現線性飄移，而非跳躍式的，這種連續性導致不同品質的數據缺乏顯著的密度邊界。

也因為缺乏密度斷層，DBSCAN 在參數設定上難以取得平衡，若將密度門檻設低整片連續的數據海會被視為同一個巨型群聚；若將密度門檻設高，演算法會對局部密度變化過於敏感。

這就是為何在結果中 DBSCAN 出現了嚴重的誤殺情況，即使在物理上是乾淨的訊號，只要其特徵點在空間中稍微分散，就會因為沒有足夠的鄰居而被判定為孤立雜訊，也就是 Label -1。這證實了基於密度的假設並不適用於特徵呈現連續分佈的生理訊號處理。

3.1.2 K-Means 的優勢

相較之下，基於劃分的 K-Means 演算法展現了更強的適應性。K-Means 不依賴密度斷層，而是透過距離強制尋找群中心，即使數據是連續分佈的，K-Means 仍然能夠定義出邊界。

本實驗結果證明，這種強制劃分的策略成功將連續的 PPG 品質化為「保留區 (Cluster 2) / 過渡區 (Cluster 0) / 雜訊區 (Cluster 1)」三個離散等級。

3.2 節律性運動的陷阱

本研究發現 DBSCAN 在處理高強度動作時發生了嚴重的誤判情況，在基於密度的分群假設時，面對節律性運動時存在邏輯漏洞。

3.2.1 DBSCAN 的劣勢

首先是動作的重複性導致特徵聚類，DBSCAN 對雜訊的假設是「稀疏的離群值」，而有效訊號是緊密的核心群聚，這個假設在處理隨機雜訊是有效的。但是當受測者以穩定的頻率行走時，感測器會接收到規律的動作干擾，這種規律性使得提取出的特徵數值表現相當穩定，不會像隨機雜訊一樣劇烈變化。因此，這些「規律的雜訊」在特徵空間中並不會散開，反而會緊密地聚集成一個高密度區塊。

由於這些節律性運動形成了高密度群聚，DBSCAN 依據其密度標準，誤將其識別為一個有效的核心群聚 (Label 1)，而非將其視為雜訊剔除掉。這也就是為甚麼在圖 8 的 Label 1 會高度集中在 Walking、Stairs 等動作，以及在圖 10 中 Label 1 的誤差會如此巨大。

DBSCAN 無法區分「規律的心跳訊號」與「規律的動作偽影」，因為兩者在特徵空間中都呈現高密度特性。

3.2.2 K-Means 的優勢

相對而言，K-Means 不受密度的蒙蔽，而是依賴特徵數值的絕對大小。儘管節律性動作的特徵很密集，但由於其訊號複雜度通常顯著高於靜止訊號，它們在空間中會位於距離原點較遠的位置。K-Means 透過最小化群內誤差平方和將這些「高數值」的樣本歸類到同一個中心 (Cluster 1)。

因此，K-Means 成功利用了特徵的「數值差異」而非「密度差異」，有效地將節律性雜訊隔離，避免了 DBSCAN 的誤判問題。

結論

本研究旨在探討非監督式學習演算法在缺乏標籤數據的現實場景中，是否能有效識別並剔除 PPG 訊號中的動作偽影。透過對真實場景數據集 (PPG-DaLiA) 的深入分析與驗證，本研究得出以下關鍵結論：

1. PPG 訊號的品質特徵在空間中呈現「連續漸變」分佈，而非離散的孤島。

DBSCAN 由於缺乏密度斷層，因此無法定義穩定的決策邊界，造成了對靜止訊號產生高達 34% 的誤判。此外，行走等「節律性運動」因產生高密度的特徵群聚反而被 DBSCAN 誤判為有效訊號而導致誤判。實驗證實，密度並非 PPG 訊號品質的可靠指標。

2. 在此次實驗中基於劃分的 K-Means 勝出，K-Means 透過中心距離的強制劃

分，成功克服了連續性分佈的挑戰。本研究證實，K-Means (K=3) 能建立出符合物理意義的品質階層：

- (1) 保留區 (Cluster 2): 鎖定低誤差的靜止訊號。
- (2) 過渡區 (Cluster 0): 容許輕微的動態干擾。
- (3) 剔除區 (Cluster 1): 精準捕捉並隔離高誤差的動作偽影。

參考文獻

- [1] M. S. Roy, R. Gupta, and K. D. Sharma, "Photoplethysmogram Signal Quality Evaluation by Unsupervised Learning Approach," in *2020 IEEE Applied Signal Processing Conference (ASPCON)*, 7-9 Oct. 2020 2020, pp. 6-10, doi: 10.1109/ASPCON49795.2020.9276733.